Lecture 3

参数学习：假设数据符合某种特定的数学表达式，通过训练数据来寻找这组固定数量的参数。

非参数学习：不对目标函数的形式做强假设。模型的复杂度不固定，而是随着训练数据量的增加而增长。通常

	参数学习	非参数学习
假设强度	~~参数学习~~ 强（假设了数据分布或函数形式）	~~非参数学习~~ 弱
参数数量	固定	随数据量增加而增加
计算时间	训练慢，需迭代。预测快	预测极慢
空间复杂度	只需存参	需保留所有训练集
缺点	易欠拟合	易过拟合

局部加权回归：

拟合 θ 去最小化 $\sum_{i=1}^{m} w^{(i)}(\theta^T x^{(i)} - y^{(i)})^2 = J(\theta)$

$w^{(i)} = \exp\left(\frac{-(x^{(i)}-x)^2}{2\tau^2}\right)$，即更注重 x 周围的数据。

局部加权回归是一种非参数学习

线性回归的概率解释：

假设 $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$，$\varepsilon^{(i)}$ 为误差，假设 $\varepsilon^{(i)}$ 之间独立同分布

不妨令 $\varepsilon^{(i)} \sim N(0, \sigma^2)$，$P(\varepsilon^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\varepsilon^{(i)})^2}{2\sigma^2}\right)$

即 $P(y^{(i)} \mid x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$，则 $y^{(i)} \mid x^{(i)}; \theta \sim N(\theta^T x^{(i)}, \sigma^2)$

定义 $L(\theta) = P(y \mid x; \theta) = \prod_{i=1}^{m} P(y^{(i)} \mid x^{(i)}; \theta)$

$= \prod_{i=1}^{m} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$

$L(\theta)$ 为参数的似然函数

为固定训练集时，参数为 θ 的概率

$l(\theta) = \log L(\theta) = \log \prod_{i=1}^{m} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$

$= \sum_{i=1}^{m} \log \frac{1}{\sqrt{2\pi}\sigma} - \sum_{i=1}^{m} \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}$

现给定数据集，寻找拟合的参数 θ，应选概率最大的 θ

即最大化似然函数 $L(\theta)$，即最大化 $l(\theta)$，最小化 $\sum_{i=1}^{m} (y^{(i)} - \theta^T x^{(i)})^2$

建立一系列概率假设。如考虑给定x,θ时y的概率，及认为误差是独立同分布的。再用最大似然估计，发现其对应的最优化问题恰好是最小二乘法，易解决。

用如上流程解决一个分类问题：输出值$y\in\{0,1\}$

逻辑回归：

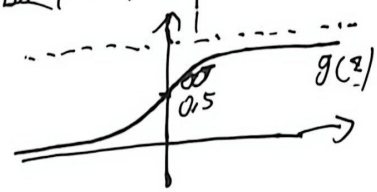

要求$h_\theta(x)\in[0,1]$

$$h_\theta(x)=g(\theta^Tx)=\frac{1}{1+e^{-\theta^Tx}}$$

$g(z)=\frac{1}{1+e^{-z}}$，称为逻辑函数

假设$P(y=1|x;\theta)=h_\theta(x)$，$P(y=0|x;\theta)=1-h_\theta(x)$

即$P(y|x;\theta)=h_\theta(x)^y(1-h_\theta(x))^{1-y}$

$$L(\theta)=P(y|x;\theta)=\prod_{i=1}^m P(y^{(i)}|x^{(i)};\theta)$$

$$=\prod_{i=1}^m h_\theta(x^{(i)})^{y^{(i)}}(1-h_\theta(x^{(i)}))^{1-y^{(i)}}$$

$$l(\theta)=\log L(\theta)=\sum_{i=1}^m\log h_\theta(x^{(i)})^{y^{(i)}}+\sum_{i=1}^m\log(1-h_\theta(x^{(i)}))^{1-y^{(i)}}$$

$$=\sum_{i=1}^m y^{(i)}\log h_\theta(x^{(i)})+\sum_{i=1}^m(1-y^{(i)})\log(1-h_\theta(x^{(i)}))$$

用批量梯度下降来最大化$l(\theta)$

即$\theta_j:=\theta_j+\alpha\frac{\partial}{\partial\theta_j}l(\theta)$

$$\frac{\partial}{\partial\theta_j}l(\theta)=\frac{\partial}{\partial\theta_j}\left(y\log g(\theta^Tx)+(1-y)\log(1-g(\theta^Tx))\right)$$

$$=\left[\frac{y}{g(\theta^Tx)}-\frac{1-y}{1-g(\theta^Tx)}\right]\frac{\partial}{\partial\theta_j}g(\theta^Tx)$$

$$g'(z)=\frac{d}{dz}\frac{1}{1+e^{-z}}=\frac{e^{-z}}{(1+e^{-z})^2}$$

$$=\frac{1}{(1+e^{-z})}\left[1-\frac{1}{(1+e^{-z})}\right]=g(z)(1-g(z))$$

故$\frac{\partial}{\partial\theta_j}l(\theta)=\left[\frac{y}{g(\theta^Tx)}-\frac{1-y}{1-g(\theta^Tx)}\right]g(\theta^Tx)(1-g(\theta^Tx))\frac{\partial}{\partial\theta_j}(\theta^Tx)$

$$=\left[y(1-g(\theta^Tx))-(1-y)g(\theta^Tx)\right]x_j$$

$$=(y-h_\theta(x))x_j$$

$$\theta_j:=\theta_j+\alpha\sum_{i=1}^m(y^{(i)}-h_\theta(x^{(i)}))x_j^{(i)}$$

牛顿法：

给定 $f(x)$，求其零点

设初值为 x_0

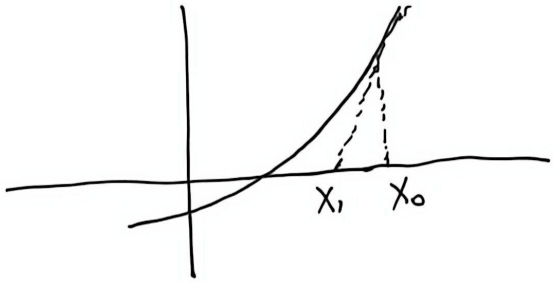

$x_1 = x_0 - \Delta$

$f'(x_0) = \frac{f(x_0)}{\Delta}$

故 $\Delta = \frac{f(x_0)}{f'(x_0)}$，则 $x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$

令 $f(\theta) = l'(\theta)$，求 $l(\theta)$ 极值，即求 $f(\theta) = l'(\theta)$ 的零点

但 θ 是向量，故 $\theta := \theta - H^{-1} \nabla_\theta l(\theta)$

H 为 Hessian 矩阵，$H_{ij} = \frac{\partial^2 l(\theta)}{\partial \theta_i \partial \theta_j}$